Analizador Léxico

Desarrollador

Juan Cardona

GitHub

UNIVERSIDAD DE ANTIOQUIA
1 8 0 3

Facultad de Ingeniería

Departamento de ingeniería de sistemas

Teoría de Lenguajes

2021-1

Introducción

Un Analizador léxico es la primera fase de un compilador, su función es la de leer la cadena de caracteres de entrada e identificar cada componente léxico o lexema asignándole un token especifico.

El método que se usé para construir el analizador léxico se realizó en los siguientes pasos:

- Creación de la lista de componentes léxicos
- AFD: Diagramas de burbujas para cada clase de lexema
- AFD: Tablas de transiciones para cada clase de lexema
- Tabla de lexemas y tokens
- Desarrollo de la aplicación

Desarrollo

Lista de componentes léxicos

El analizador léxico acepta palabras reservadas, identificadores, constantes numéricas, contantes alfabéticas, operaciones aritméticas y separadores.

- Palabras reservadas (keyword):
  - int
  - float
  - string
  - bool
  - if
  - else
- Identificadores (identify): nombres de variables, funciones o clases creadas por el usuario. Constantes alfanuméricas, no inician con un número.
- Constantes numéricas (numConst): números enteros positivos y números flotantes.
  - D (cualquier caracter numérico o dígito)
  - ,
- Constantes alfabéticas (charConst): cadenas de caracteres
  - L (cualquier carácter alfabético, en minúscula o mayúscula, o letra)
- Operaciones aritméticas (operator):
  - +
  - -
  - *
  - /
  - =
  - <
  - <=
  - <>
  - >
  - >=
  - ==
- Separadores (separator):
  - (
  -)
  - {
  - }
  - ;

AFD: Diagramas de burbujas para cada clase de lexema

Para los AFD se consideraron una lista de caracteres de ingreso partiendo de la lista de componentes léxicos y se seleccionaron, mediante los caracteres necesarios para asignarle a cada tipo de lexema, un token especifico correspondiente en los AFD a los estados de aceptación.

AFD1: keyword

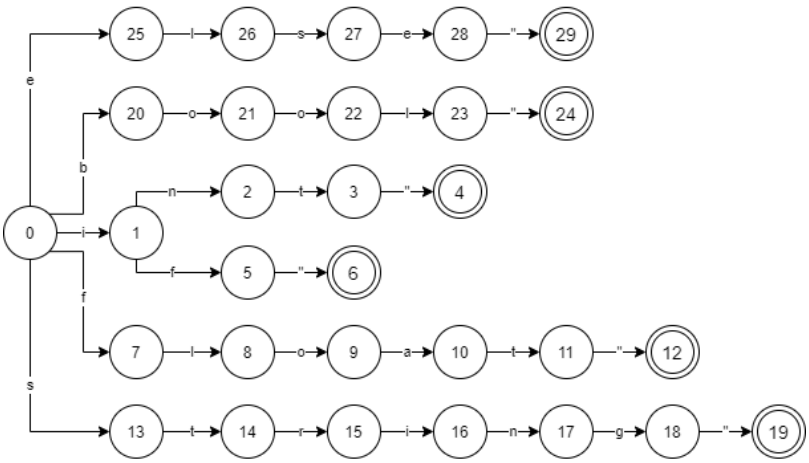

AFD2: identify, numConst, charConst

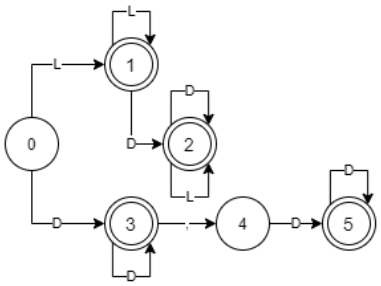

AFD3: operator, separator

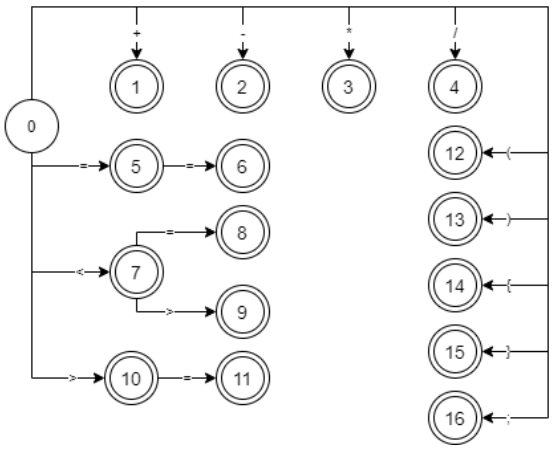

AFD: Tablas de transiciones para cada clase de lexema

Partiendo de cada diagrama de burbujas se determinaron las siguientes tablas de transiciones y se le asignaron a cada estado de aceptación un token correspondiente al lexema que se identifica en las secuencias de símbolos de entrada.

ADF1: keyword

	e	**s**	**l**	**b**	**o**	**g**	**r**	**n**	**t**	**f**	**a**	**d**	**u**	**i**		
0	20	10		16						5				1	0	
1								2		4					0	
2									3						0	
3															**1**	INT
4															**1**	IF
5			6												0	
6					7										0	
7											8				0	
8									9						0	
9															**1**	FLOAT
10									11						0	
11							12								0	
12														13	0	
13								14							0	
14						15									0	
15															**1**	STRING
16					17										0	
17					18										0	
18			19												0	
19															**1**	BOOL
20			21												0	
21		22													0	
22	23														0	
23															**1**	ELSE

AFD2: identify, numConst, charConst

- D (cualquier caracter numérico o dígito)
- L (cualquier carácter alfabético, en minúscula o mayúscula, o letra)

	L	**D**	**,**	
0	1	3		0
1	1	2		**1**
2	2	2		**1**
3		3	4	**1**
4		5		0
5		5		**1**

CHARCONST
IDENTIFY
INTCONST
FLOATCONST

ADF3: operator, separator

	+	**-**	*****	**/**	**=**	**<**	**>**	**(**	**)**	**{**	**}**	**;**	
0	1	2	3	4	5	7	10	12	13	14	15	16	0
1													**1**
2													**1**
3													**1**
4													**1**
5					6								**1**
6													**1**
7					8		9						**1**
8													**1**
9													**1**
10					11								**1**
11													**1**
12													**1**
13													**1**
14													**1**
15													**1**
16													**1**

PLUS
MINUS
MULTIPLICATION
DIVISION
ASIGNATION
BOOLCOPARISON
MINOR
MINOREQUAL
DIFFERENT
HIGHER
HIGHEREQUAL
OPENPARENTHESIS
CLOSEPARENTHESIS
OPENBRACKETS
CLOSEBRACKETS
SEMICOLON

Tabla de lexemas y tokens

De cada estado de aceptación obtenemos la lista de tokens para cada lexema que reconoce el analizador léxico, nótese que el espacio en blanco no es tomado en cuenta, su presencia es irrelevante.

Lexema	Token
esle	ELSE
bool	BOOL
int	INT
if	IF
float	FLOAT
string	STRING
L^+	CHARCONST
$L^+(L+D)^*$	IDENTIFY
D^+	INTCONST
D^+,D^+	FLOATCONST
+	PLUS
-	MINUS
*	MULTIPLICATION
/	DIVISION
=	ASIGNATION
==	BOOLCOPARISON
<	MINOR
<=	MINOREQUAL
<>	DIFFERENT
>	HIGHER
>=	HIGHEREQUAL
(	OPENPARENTHESIS
)	CLOSEPARENTHESIS
{	OPENBRACKETS
}	CLOSEBRACKETS
;	SEMICOLON

Estos lexemas se representan por una expresión regular

Desarrollo de la aplicación

Para ver el código, la documentación y el archivo ejecutable con el analizador léxico visitar el siguiente repositorio: https://github.com/ohmono/analizador-lexico

Bibliografía

- Flórez Rueda, R. (2010). Introducción a los compiladores. Medellín, Colombia: Universidad de Antioquia